



Санкт-Петербургский
государственный университет

Факультет прикладной математики —
процессов управления

Саратовская область: сбор данных, парсинг, анализ

Росстат · «Работа в России» · OpenStreetMap

Санкт-Петербург, 2026

Сбор данных: источники и файлы

Четыре источника, девять скриптов, один слой `steps/`

Источник	Скрипты	Что получаем	Файл в проекте
Росстат, сборник «Регионы России — 2025»	<code>download_rosstat</code> <code>rosstat_docx_to_text</code> <code>rosstat_extract_region</code>	476 таблиц со строкой «Саратовская область»: номер таблицы, шапка, значения	<code>data/rosstat/saratov_tables.json</code>
Портал «Работа в России» (API)	<code>parse_vacancies_trudvsem</code>	4 183 вакансии × 15 полей: профессия, зарплата, работодатель, координаты	<code>data/labor/vacancies.csv</code>
OpenStreetMap (выгрузка Geofabrik)	<code>download_osm_pbf</code> <code>parse_osm_objects</code>	2 432 объекта: банки и банкоматы, магазины, услуги, производства	<code>data/osm/objects.csv</code>
Nominatim (справочная геометрия)	<code>get_region_boundary</code> <code>assign_cities</code>	контур области из 8 307 точек и привязка объектов к 27 городам	<code>data/osm/region_boundary.geojson</code> , <code>objects_by_city.csv</code>

Скачивание и разбор вынесены в общий слой `scripts/steps/` — эти данные нужны всем сферам: банки и магазины лежат в одном файле OSM, разделы статистики — в одном архиве.

Источник 1. Росстат: от архива до таблиц

Как 823 таблицы сборника превращаются в выборку по региону

Шаг	Скрипт	Что делает	Результат
1. Скачать	download_rosstat	Забирает .rar (11 МБ) и .pdf сборника с сайта Росстата	22 раздела .docx после распаковки
2. Прочитать	rosstat_docx_to_text	Обходит XML-тело каждого .docx, чтобы сохранить порядок абзацев и таблиц, и пишет текст	23 дампа, 823 таблицы
3. Отобрать	rosstat_extract_region	Ищет «Саратовская область» в любой ячейке строки, сохраняет номер таблицы, шапку и строки региона	saratov_tables.json — 476 таблиц

Почему сохраняется вся шапка: номер таблицы и подписи столбцов позволяют потом читать конкретное значение — «табл. 20.10, 2025 год, вклады физических лиц» — не переписывая цифры в код.

Особенность вёрстки: части одной таблицы идут отдельными блоками без подписи, а регион в «продолжениях» стоит в последней ячейке. Поэтому номер таблицы наследуется от подписи, а поиск идёт по любой ячейке строки — иначе терялось бы 79 таблиц из 476.

Источник 2. Вакансии: обход лимита API

«Работа в России», регион 6400000000000

Ограничение API: $\text{offset} + \text{limit} \leq 200$

- Штатная пагинация невозможна: на второй странице сервис отвечает ошибкой.
- Решение — перебор не по страницам, а по 129 ключевым словам профессий.
- На каждое слово до 2 страниц по 100 записей, 5 потоков параллельно.
- Дедупликация — структурой данных: словарь по id вакансии, повторы исчезают сами.
- Повторы запросов: 3 попытки с растущей паузой; неудача одного слова не рвёт сбор.

```
def collect_kw(kw):  
    got = {}  
    for offset in (0, 100):  
        d = fetch(kw, offset)  
        for item in d["results"]["vacancies"]:  
            got[item["vacancy"]["id"]] = item  
        if len(vacs) < 100:  
            break  
    return kw, got
```

Результат: 4 183 уникальные вакансии из 7 939 активных (52,7%)

- Файл data/labor/vacancies.csv — 4 183 строки × 15 колонок (2,2 МБ).
- Рядом vacancies_raw.json — 4 183 сырых ответа API (14,7 МБ).
- Ограничение: выборка смещена к профессиям из списка ключевых слов.

Источник 3. OpenStreetMap: объекты области

Выгрузка Geofabrik и отбор по тегам

Шаг	Что происходит	Числа
Скачивание	download_osm_pbf: выгрузка Приволжского федерального округа с Geofabrik	739 МБ
Разбор	parse_osm_objects: osmium проходит файл потоком, объекты не держатся в памяти	112 млн узлов, 11 млн линий
Отбор по тегам	amenity=bank atm; industrial=*; shop=supermarket convenience general; shop=beauty hairstylist massage; leisure=tanning_salon	47 658 кандидатов
Фильтр по границе	лучевой метод, точки внутри контура области	2 432 объекта

Точки (node) берутся как есть, площадки (way) — по центру масс их вершин. Один объект может попасть в несколько категорий: магазин с аптекой — и торговля, и услуги.

Почему выгрузка, а не Overpass API: сервис блокировал запросы по области. Локальный разбор не зависит от чужого API и даёт все объекты региона, а не только попавшие в ответ.

Геометрия: зачем нужен контур области

Фильтр по границе и привязка объектов к городам

Проблема: прямоугольник вокруг области захватывает пять соседних регионов и Казахстан

Поэтому объекты фильтруются по реальному контуру, полученному из Nominatim: 8 307 точек.

```
def ray_inside(poly, pts):      # точка внутри, если луч пересекает контур нечётно раз
    x1, y1 = poly[None, :, 0], poly[None, :, 1]
    x2 = np.roll(poly[:, 0], -1)[None, :]  # соседняя вершина ребра
    cond = (y1 > y) != (y2 > y)             # ребро пересекает горизонталь точки
    xint = (x2 - x1) * (y - y1) / (y2 - y1) + x1
    return (cond & (x < xint)).sum(axis=1) % 2 == 1
```

```
def inside(pts, batch=800):      # батчи: 800 x 8 307 — около 53 МБ на массив
    ...
```

- 47 658 объектов × 8 307 вершин — цикл на Python занял бы часы.
- Матрица «точка × ребро» считается в numpy сразу для всех точек.
- Порция 800 точек ограничивает память: полная матрица заняла бы ~3 ГБ.

Привязка к городам (assign_cities)

- В OSM поле города заполнено редко, поэтому город определяется по ближайшему из 27 населённых пунктов.
- Расстояние — равноугольная аппроксимация (111 км на градус с поправкой на косинус широты); сравниваются квадраты расстояний, корень берётся один раз.
- Если ближайший город дальше 30 км, объект попадает в группу «прочие населённые пункты» — иначе он приписался бы городу в десятках километров. В пределах 30 км оказалось 96% объектов.

Что получилось после сбора

Файлы, с которыми работают скрипты анализа

Файл	Размер	Объём	Что внутри
data/rosstat/saratov_tables.json	0,6 МБ	476 таблиц	номер таблицы, шапка (годы и подписи), строки региона
data/labor/vacancies.csv	2,2 МБ	4 183 × 15	профессия, зарплата от и до, работодатель, ИНН, координаты, опыт
data/osm/objects.csv	0,2 МБ	2 432 × 14	тип, категория, название, координаты, адрес, бренд, теги
data/osm/objects_by_city.csv	0,3 МБ	2 432 × 15	то же плюс колонка settlement — привязанный город
data/osm/region_boundary.geojson	0,2 МБ	8 307 точек	контур области из Nominatim

В репозиторий не входят крупные исходники (выгрузка OSM 739 МБ, архив и PDF сборника, сырые ответы API) — они восстанавливаются запуском скриптов слоя steps.

Дальше эти файлы читают четыре скрипта анализа: `overview.py`, `finance.py`, `labor.py`, `goods.py`. Каждый печатает свой блок отчёта и пишет таблицы в `analiz/`.

Общий анализ области

overview.py: регион в цифрах из таблиц 1.1, 1.7, 2.1, 2.3, 9.2

Как скрипт берёт числа

```
t = rv.load(PROJECT)          # saratov_tables.json
area = rv.require(t, "1.1", label="Площадь территории")
pop = rv.require(t, "1.1", label="Численность населения")
grp = rv.require(t, "1.1", label="Валовой региональный продукт")
grp_pc = rv.require(t, "9.2", year=2023)
pop_2010 = rv.require(t, "2.1", year=2010)
```

Адресация: «номер таблицы + год + подпись столбца». Если столбец не найден, скрипт падает с ошибкой — пустое значение не подставляется.

101,2

тыс. км²
площадь

2 385,2

тыс. человек
население

1 147,9

тыс. человек
занятых

1 345

млрд ₽
ВРП, 2023

561 624

₽ ВРП на душу

58 626

₽ зарплата

316,7

млрд ₽
инвестиции


328

муниципальны
х
образований

- Население сократилось на 5,3% с 2010 г. (2 519,3 → 2 385,2 тыс.), а ВРП вырос в 3,6 раза.
- Городское население — 77,0%; в области 37 районов и 4 городских округа.
- Инвестиции составляют 23,5% ВРП.


Общий анализ: структура экономики

Секторы считаются как суммы видов деятельности



■ Первичный ■ Вторичный ■ Третичный

ВРП, 2023 · таблица 9.4



■ Первичный ■ Вторичный ■ Третичный

Занятость, 2024 · таблица 3.6

Как считаются секторы

- Первичный = сельское хозяйство + добыча.
- Вторичный = обработка + энергетика + водоснабжение + строительство.
- Третичный = 100% минус первые два — остальные услуги.
- Те же суммы считаются в двух разрезах: по ВРП и по занятости.
- Сравнение разрезов и даёт вывод: в первичном секторе доля в ВРП вдвое больше доли в занятости.

Формы собственности (табл. 12.4, 12.7): частный сектор — 81,6% организаций и 79,9% оборота; государство и муниципалитеты — 12,9% организаций и 3,6% оборота.

Финансовый сектор: как считает finance.py

Таблицы 20.9–20.14 сборника + объекты OSM

Что считаем	Откуда берём	Как
Институты: организации и филиалы	табл. 20.9, части 1 и 2	значения на 2011 и 2025 гг. и кратность изменений
Вклады: всего, населения, юрлиц	табл. 20.10	по году и подписи столбца («физических» / «юридических»)
Кредиты юрлицам	табл. 20.14	ряд 2011 → 2025
Сбербанк и его доля	табл. 20.12, 20.13	вклады физлиц в рублях и валюте; доля = вклады Сбербанка / все вклады населения
Вклады на душу населения	табл. 20.10 + население	вклады ÷ население (ближайшие опубликованные годы)
Размещение: банки, банкоматы, бренды	objects_by_city.csv	группировка по категории, бренду и территории

```
dep_p1 = rv.require(t, "20.10", year=2025, label="физических", part=1) # 514 711
share = 100 * sber1 / dep_p1 # 51,8%
```

Выход: analiz/финансы_ряды.csv (ряды и кратность) и analiz/финансы_бренды.csv (топ банков).

Финансовый сектор: результаты

Что показали данные

Институты (на начало года)	2011	2025	Деньги, млн ₽	2011	2025	×
Кредитные организации	10	4	Вклады всего	97 314	585 130	6,0
Филиалы	66	3	— населения	90 263	514 711	5,7
			— юридических лиц	7 051	70 419	10,0
			Кредиты юрлицам	74 345	219 109	2,9

- Вклады на душу населения: 38 627 ₽ (2011) → 245 317 ₽ (2025).
- Сбербанк: 266 542 млн ₽ на рублёвых счетах физлиц — 51,8% всех вкладов населения, 23-е место в РФ.
- Размещение (OSM): 547 объектов — 237 банков и 310 банкоматов, то есть 1 : 1,3.
- Топ брендов: Сбербанк 181, Совкомбанк 35, ВТБ 32, Росбанк 25, Промсвязьбанк 24.
- Территории: Саратов 372 объекта, Балаково 43, Энгельс 39, прочие 93.

Ограничение: таблица 20.9 считает филиалы, а не дополнительные офисы и кассы; доля Сбербанка сопоставляет его рублёвые вклады (данные банка) со всеми вкладами населения (данные Банка России).

Рынок труда: как считает labor.py

Вакансии из API + статистика Росстата

Что считаем	Откуда берём	Как
Полнота данных	vacancies.csv	доля вакансий с зарплатой (99,8%) и с координатами (96,1%)
Распределение зарплат	vacancies.csv, поле salary_min	минимум, квартили, медиана, средняя, максимум; нули трактуются как «не указано»
Топы профессий и сфер	vacancies.csv	подсчёт частот; для каждой сферы — своя медиана зарплаты
Требования к опыту	vacancies.csv, поле experience	доли вакансий по числу требуемых лет
Концентрация работодателей	vacancies.csv	доля топ-10 и число работодателей с одной вакансией
Фактическая занятость и оплата	табл. 1.1, 4.6	занятые и средняя начисленная зарплата за 2024 г.

```
sal = [float(r["salary_min"]) for r in rows if r["salary_min"].strip()]
sal = [s for s in sal if s > 0]          # 0 в поле означает «не указана»
med = st.median(sal)                    # 38 000 ₽
q  = st.quantiles(sal, n=4)             # 28 500 ... 50 000 ₽
```

Выход: analiz/вакансии_топ_профессий.csv и analiz/вакансии_по_сферам.csv (с медианами по сферам).

Рынок труда: результаты

Спрос по вакансиям и фактическая статистика

4 183

вакансии
в выборке

38 000 ₽

медиана
предлагаемой

45 349 ₽

средняя
предлагаемая

58 626 ₽

средняя
фактическая

Распределение предлагаемых зарплат: 13 000 ₽ минимум · 28 500 ₽ 1-й квартиль · 38 000 ₽ медиана · 45 349 ₽ средняя · 50 000 ₽ 3-й квартиль · 275 000 ₽ максимум

Сферы: число вакансий и медиана предлагаемой зарплаты

Сфера	Вакансий	Медиана, ₽	Сфера	Вакансий	Медиана, ₽
Здравоохранение	588	31 134	Транспорт, логистика	213	50 000
Продажи, торговля	460	43 000	Сельское хозяйство	184	35 000
Образование, наука	439	27 093	Электроэнергетика	182	52 529
Производство	360	45 200	Рабочие специальности	170	45 000
ЖКХ, эксплуатация	235	32 000	Строительство	115	50 767

- 88,5% вакансий — на опыт от нуля до одного года; топ профессий: продавец-кассир, пекарь, дворник.
- Топ-10 работодателей дают 22,2% вакансий, при этом 476 работодателей имеют одну вакансию.

Рынок товаров и услуг: как считает goods.py

Объекты OSM + стоимостной разрез из статистики

Что считаем	Откуда берём	Как
Форматы магазинов	objects_by_city.csv, shop	подсчёт по значениям supermarket / convenience / general и их доли
Торговые сети	objects_by_city.csv, brand и operator	частота брендов; доля объектов с указанной сетью
Производства по видам	objects_by_city.csv, industrial	частота видов и доля нефти и газа
Территории	objects_by_city.csv, settlement	магазины, услуги и производства по городам; доли трёх крупнейших городов
Промышленность, АПК, розница	табл. 1.1, вторая часть	отгрузка по четырём видам деятельности; сумма — это промышленность всего
Соотношение размещения и денег	оба источника	объекты сопоставляются с миллиардами рублей: размещение и масштаб — разные вещи

```
manuf = rv.require(t, "1.1", label="обрабатывающие производства", part=1) # 799
mining = rv.require(t, "1.1", label="добыча полезных ископаемых", part=1) # 70,4
industry = mining + manuf + energy + water # 1 039,3
```

Выход: analiz/объекты_по_городам.csv (52 территории) и analiz/товары_сводка.csv.

Рынок товаров и услуг: результаты

Размещение объектов и денежный масштаб

Форматы магазинов	Объектов	Доля
Магазин у дома	951	60,3%
Супермаркет	621	39,4%
Общий профиль	4	0,3%

Производства по видам	Объектов
factory — завод	12
oil — нефть	10
gas — газ	9
склады, цемент, прочие	10

Всего в блоке: 1 576 магазинов · 268 объектов услуг · 41 производство

- Торговые сети: Магнит 122, Пятёрочка 94, Гроздь 22; сетей 33, но бренд указан лишь у 20,7% магазинов.
- Территории: 63,5% магазинов — в Саратове, Балаково и Энгельсе; на Саратов приходится 41,5%.
- Деньги: промышленность 1 039,3 млрд ₽ (из них обработка 799), АПК 282,1 млрд ₽, розница 648,5 млрд ₽.
- 46% размеченных производств — нефть и газ; адрес улицы указан только у 18,9% объектов OSM.

Главное противоречие: по объектам магазинов в 38 раз больше, чем производств, а по деньгам промышленность больше розницы в 1,6 раза. OSM описывает размещение, статистика — масштаб.

Выводы

- Собран полный набор данных: 476 таблиц сборника, 4 183 вакансии, 2 432 объекта OSM — всё скриптами, числа в аналитике не переписаны вручную.
- Экономика индустриально-аграрная: третичный сектор 54,1% ВРП и 66,6% занятости, реальный сектор — 31,4% ВРП.
- Население сокращается (–5,3% с 2010 г.) при росте ВРП в 3,6 раза — рост за счёт производительности.
- Финансовый сектор: сеть сжалась в 22 раза (66 → 3 филиала), вклады выросли в 6 раз — до 585,1 млрд ₽; 51,8% вкладов населения — в Сбербанке.
- Рынок труда: медиана предлагаемой зарплаты 38 000 ₽ против 58 626 ₽ средней фактической; самый высокий спрос — в сферах с самой низкой оплатой.
- Рынок товаров и услуг: 63,5% магазинов в трёх городах; промышленность по деньгам больше розницы в 1,6 раза, хотя по числу объектов картина обратная.
- Ограничения: выборка вакансий 52,7% и смещена к ключевым словам; OSM неполон по промышленным объектам; показатели в текущих ценах.
- Развитие: второй источник вакансий, снятие смещения выборки, дефляция рядов, карта объектов по координатам.