



Санкт-Петербургский  
государственный университет

Факультет прикладной математики —  
процессов управления

# Саратовская область: сбор данных, парсинг, анализ

Росстат · «Работа в России» · OpenStreetMap

Санкт-Петербург, 2026

# Сбор данных: источники и файлы

Четыре источника, девять скриптов, один слой `steps/`

| Источник                                 | Скрипты                                                                                                   | Что получаем                                                                | Файл в проекте                                                                      |
|------------------------------------------|-----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|-------------------------------------------------------------------------------------|
| Росстат, сборник «Регионы России — 2025» | <code>download_rosstat</code><br><code>rosstat_docx_to_text</code><br><code>rosstat_extract_region</code> | 476 таблиц со строкой «Саратовская область»: номер таблицы, шапка, значения | <code>data/rosstat/saratov_tables.json</code>                                       |
| Портал «Работа в России» (API)           | <code>parse_vacancies_trudvsem</code>                                                                     | 4 183 вакансии × 15 полей: профессия, зарплата, работодатель, координаты    | <code>data/labor/vacancies.csv</code>                                               |
| OpenStreetMap (выгрузка Geofabrik)       | <code>download_osm_pbf</code><br><code>parse_osm_objects</code>                                           | 2 432 объекта: банки и банкоматы, магазины, услуги, производства            | <code>data/osm/objects.csv</code>                                                   |
| Nominatim (справочная геометрия)         | <code>get_region_boundary</code><br><code>assign_cities</code>                                            | контур области из 8 307 точек и привязка объектов к 27 городам              | <code>data/osm/region_boundary.geojson</code> ,<br><code>objects_by_city.csv</code> |

Скачивание и разбор вынесены в общий слой `scripts/steps/` — эти данные нужны всем сферам: банки и магазины лежат в одном файле OSM, разделы статистики — в одном архиве.

# Источник 1. Росстат: от архива до таблиц

Как 823 таблицы сборника превращаются в выборку по региону

| Шаг           | Скрипт                 | Что делает                                                                                        | Результат                         |
|---------------|------------------------|---------------------------------------------------------------------------------------------------|-----------------------------------|
| 1. Скачать    | download_rosstat       | Забирает .rar (11 МБ) и .pdf сборника с сайта Росстата                                            | 22 раздела .docx после распаковки |
| 2. Прочитать  | rosstat_docx_to_text   | Обходит XML-тело каждого .docx, чтобы сохранить порядок абзацев и таблиц, и пишет текст           | 23 дампа, 823 таблицы             |
| 3. Отобразить | rosstat_extract_region | Ищет «Саратовская область» в любой ячейке строки, сохраняет номер таблицы, шапку и строки региона | saratov_tables.json — 476 таблиц  |

Почему сохраняется вся шапка: номер таблицы и подписи столбцов позволяют потом читать конкретное значение — «табл. 20.10, 2025 год, вклады физических лиц» — не переписывая цифры в код.

Особенность вёрстки: части одной таблицы идут отдельными блоками без подписи, а регион в «продолжениях» стоит в последней ячейке. Поэтому номер таблицы наследуется от подписи, а поиск идёт по любой ячейке строки — иначе терялось бы 79 таблиц из 476.

# Источник 2. Вакансии: обход лимита API

«Работа в России», регион 6400000000000

## Ограничение API: $\text{offset} + \text{limit} \leq 200$

- Штатная пагинация невозможна: на второй странице сервис отвечает ошибкой.
- Решение — перебор не по страницам, а по 129 ключевым словам профессий.
- На каждое слово до 2 страниц по 100 записей, 5 потоков параллельно.
- Дедупликация — структурой данных: словарь по id вакансии, повторы исчезают сами.
- Повторы запросов: 3 попытки с растущей паузой; неудача одного слова не рвёт сбор.

```
def collect_kw(kw):  
    got = {}  
    for offset in (0, 100):  
        d = fetch(kw, offset)  
        for item in d["results"]["vacancies"]:  
            got[item["vacancy"]["id"]] = item  
        if len(vacs) < 100:  
            break  
    return kw, got
```

**Результат: 4 183 уникальные вакансии из 7 939 активных (52,7%)**

- Файл data/labor/vacancies.csv — 4 183 строки × 15 колонок (2,2 МБ).
- Рядом vacancies\_raw.json — 4 183 сырых ответа API (14,7 МБ).
- Ограничение: выборка смещена к профессиям из списка ключевых слов.

## Источник 3. OpenStreetMap: объекты области

Выгрузка Geofabrik и отбор по тегам

| Шаг               | Что происходит                                                                                                                  | Числа                          |
|-------------------|---------------------------------------------------------------------------------------------------------------------------------|--------------------------------|
| Скачивание        | download_osm_pbf: выгрузка Приволжского федерального округа с Geofabrik                                                         | 739 МБ                         |
| Разбор            | parse_osm_objects: osmium проходит файл потоком, объекты не держатся в памяти                                                   | 112 млн узлов,<br>11 млн линий |
| Отбор по тегам    | amenity=bank atm; industrial=*; shop=supermarket convenience general;<br>shop=beauty hairstylist massage; leisure=tanning_salon | 47 658 кандидатов              |
| Фильтр по границе | лучевой метод, точки внутри контура области                                                                                     | 2 432 объекта                  |

Точки (node) берутся как есть, площадки (way) — по центру масс их вершин. Один объект может попасть в несколько категорий: магазин с аптекой — и торговля, и услуги.

Почему выгрузка, а не Overpass API: сервис блокировал запросы по области. Локальный разбор не зависит от чужого API и даёт все объекты региона, а не только попавшие в ответ.

# Геометрия: зачем нужен контур области

Фильтр по границе и привязка объектов к городам

Проблема: прямоугольник вокруг области захватывает пять соседних регионов и Казахстан

Поэтому объекты фильтруются по реальному контуру, полученному из Nominatim: 8 307 точек.

```
def ray_inside(poly, pts):      # точка внутри, если луч пересекает контур нечётно раз
    x1, y1 = poly[None, :, 0], poly[None, :, 1]
    x2 = np.roll(poly[:, 0], -1)[None, :]    # соседняя вершина ребра
    cond = (y1 > y) != (y2 > y)              # ребро пересекает горизонталь точки
    xint = (x2 - x1) * (y - y1) / (y2 - y1) + x1
    return (cond & (x < xint)).sum(axis=1) % 2 == 1
```

```
def inside(pts, batch=800):      # батчи: 800 x 8 307 — около 53 МБ на массив
    ...
```

- 47 658 объектов × 8 307 вершин — цикл на Python занял бы часы.
- Матрица «точка × ребро» считается в numpy сразу для всех точек.
- Порция 800 точек ограничивает память: полная матрица заняла бы ~3 ГБ.

## Привязка к городам (assign\_cities)

- В OSM поле города заполнено редко, поэтому город определяется по ближайшему из 27 населённых пунктов.
- Расстояние — равноугольная аппроксимация (111 км на градус с поправкой на косинус широты); сравниваются квадраты расстояний, корень берётся один раз.
- Если ближайший город дальше 30 км, объект попадает в группу «прочие населённые пункты» — иначе он приписался бы городу в десятках километров. В пределах 30 км оказалось 96% объектов.

# Что получилось после сбора

Файлы, с которыми работают скрипты анализа

| Файл                             | Размер | Объём       | Что внутри                                                       |
|----------------------------------|--------|-------------|------------------------------------------------------------------|
| data/rosstat/saratov_tables.json | 0,6 МБ | 476 таблиц  | номер таблицы, шапка (годы и подписи), строки региона            |
| data/labor/vacancies.csv         | 2,2 МБ | 4 183 × 15  | профессия, зарплата от и до, работодатель, ИНН, координаты, опыт |
| data/osm/objects.csv             | 0,2 МБ | 2 432 × 14  | тип, категория, название, координаты, адрес, бренд, теги         |
| data/osm/objects_by_city.csv     | 0,3 МБ | 2 432 × 15  | то же плюс колонка settlement — привязанный город                |
| data/osm/region_boundary.geojson | 0,2 МБ | 8 307 точек | контур области из Nominatim                                      |

В репозиторий не входят крупные исходники (выгрузка OSM 739 МБ, архив и PDF сборника, сырые ответы API) — они восстанавливаются запуском скриптов слоя steps.

Дальше эти файлы читают четыре скрипта анализа: `overview.py`, `finance.py`, `labor.py`, `goods.py`. Каждый печатает свой блок отчёта и пишет таблицы в `analiz/`.

# Общий анализ области

overview.py: регион в цифрах из таблиц 1.1, 1.7, 2.1, 2.3, 9.2

## Как скрипт берёт числа

```
t = rv.load(PROJECT)                # saratov_tables.json
area = rv.require(t, "1.1", label="Площадь территории")
pop = rv.require(t, "1.1", label="Численность")
grp = rv.require(t, "1.1", label="Валовой продукт")
grp_pc = rv.require(t, "9.2", year=2023)
pop_2010 = rv.require(t, "2.1", year=2010)
```

Адресация: «номер таблицы + год + подпись столбца». Если столбец не найден, скрипт падает с ошибкой — пустое значение не подставляется.

**101,2**

тыс. км<sup>2</sup>  
площадь

**2 385,2**

тыс. человек  
население

**1 147,9**

тыс. человек  
занятых

**1 345**

млрд ₽  
ВРП, 2023

**561 624**

₽ ВРП на душу

**58 626**

₽ зарплата

**316,7**

млрд ₽  
инвестиции


**328**

муниципальных  
образований

- Население сократилось на 5,3% с 2010 г. (2 519,3 → 2 385,2 тыс.), а ВРП вырос в 3,6 раза.
- Городское население — 77,0%; в области 37 районов и 4 городских округа.
- Инвестиции составляют 23,5% ВРП.


# Общий анализ: структура экономики

Секторы считаются как суммы видов деятельности



■ Первичный ■ Вторичный ■ Третичный

**ВРП, 2023 · таблица 9.4**



■ Первичный ■ Вторичный ■ Третичный

**Занятость, 2024 · таблица 3.6**

## Как считаются секторы

- Первичный = сельское хозяйство + добыча.
- Вторичный = обработка + энергетика + водоснабжение + строительство.
- Третичный = 100% минус первые два — остальные услуги.
- Те же суммы считаются в двух разрезах: по ВРП и по занятости.
- Сравнение разрезов и даёт вывод: в первичном секторе доля в ВРП вдвое больше доли в занятости.

Формы собственности (табл. 12.4, 12.7): частный сектор — 81,6% организаций и 79,9% оборота; государство и муниципалитеты — 12,9% организаций и 3,6% оборота.

# Финансовый сектор: как считает finance.py

Таблицы 20.9–20.14 сборника + объекты OSM

| Что считаем                          | Откуда берём            | Как                                                                             |
|--------------------------------------|-------------------------|---------------------------------------------------------------------------------|
| Институты: организации и филиалы     | табл. 20.9, части 1 и 2 | значения на 2011 и 2025 гг. и кратность изменений                               |
| Вклады: всего, населения, юрлиц      | табл. 20.10             | по году и подписи столбца («физических» / «юридических»)                        |
| Кредиты юрлицам                      | табл. 20.14             | ряд 2011 → 2025                                                                 |
| Сбербанк и его доля                  | табл. 20.12, 20.13      | вклады физлиц в рублях и валюте; доля = вклады Сбербанка / все вклады населения |
| Вклады на душу населения             | табл. 20.10 + население | вклады ÷ население (ближайшие опубликованные годы)                              |
| Размещение: банки, банкоматы, бренды | objects_by_city.csv     | группировка по категории, бренду и территории                                   |

```
dep_p1 = rv.require(t, "20.10", year=2025, label="физических", part=1) # 514 711
share = 100 * sber1 / dep_p1 # 51,8%
```

Выход: analiz/финансы\_ряды.csv (ряды и кратность) и analiz/финансы\_бренды.csv (топ банков).

# Финансовый сектор: результаты

Что показали данные

| Институты (на начало года) | 2011 | 2025 | Деньги, млн ₽     | 2011   | 2025    | ×    |
|----------------------------|------|------|-------------------|--------|---------|------|
| Кредитные организации      | 10   | 4    | Вклады всего      | 97 314 | 585 130 | 6,0  |
| Филиалы                    | 66   | 3    | — населения       | 90 263 | 514 711 | 5,7  |
|                            |      |      | — юридических лиц | 7 051  | 70 419  | 10,0 |
|                            |      |      | Кредиты юрлицам   | 74 345 | 219 109 | 2,9  |

- Вклады на душу населения: 38 627 ₽ (2011) → 245 317 ₽ (2025).
- Сбербанк: 266 542 млн ₽ на рублёвых счетах физлиц — 51,8% всех вкладов населения, 23-е место в РФ.
- Размещение (OSM): 547 объектов — 237 банков и 310 банкоматов, то есть 1 : 1,3.
- Топ брендов: Сбербанк 181, Совкомбанк 35, ВТБ 32, Росбанк 25, Промсвязьбанк 24.
- Территории: Саратов 372 объекта, Балаково 43, Энгельс 39, прочие 93.

Ограничение: таблица 20.9 считает филиалы, а не дополнительные офисы и кассы; доля Сбербанка сопоставляет его рублёвые вклады (данные банка) со всеми вкладами населения (данные Банка России).

# Рынок труда: как считает labor.py

Вакансии из API + статистика Росстата

| Что считаем                    | Откуда берём                   | Как                                                                             |
|--------------------------------|--------------------------------|---------------------------------------------------------------------------------|
| Полнота данных                 | vacancies.csv                  | доля вакансий с зарплатой (99,8%) и с координатами (96,1%)                      |
| Распределение зарплат          | vacancies.csv, поле salary_min | минимум, квартили, медиана, средняя, максимум; нули трактуются как «не указано» |
| Топы профессий и сфер          | vacancies.csv                  | подсчёт частот; для каждой сферы — своя медиана зарплаты                        |
| Требования к опыту             | vacancies.csv, поле experience | доли вакансий по числу требуемых лет                                            |
| Концентрация работодателей     | vacancies.csv                  | доля топ-10 и число работодателей с одной вакансией                             |
| Фактическая занятость и оплата | табл. 1.1, 4.6                 | занятые и средняя начисленная зарплата за 2024 г.                               |

```

sal = [float(r["salary_min"]) for r in rows if r["salary_min"].strip()]
sal = [s for s in sal if s > 0]          # 0 в поле означает «не указана»
med = st.median(sal)                    # 38 000 ₽
q  = st.quantiles(sal, n=4)             # 28 500 ... 50 000 ₽

```

Выход: analiz/вакансии\_топ\_профессий.csv и analiz/вакансии\_по\_сферам.csv (с медианами по сферам).

# Рынок труда: результаты

Спрос по вакансиям и фактическая статистика

**4 183**

вакансии  
в выборке

**38 000 ₽**

медиана  
зарплаты

**45 349 ₽**

средняя  
предлагаемая

**58 626 ₽**

средняя  
фактическая

Предлагаемые зарплаты, ₽: минимум 13 000 · 1-й квартиль 28 500 · медиана 38 000  
средняя 45 349 · 3-й квартиль 50 000 · максимум 275 000

## Сферы: число вакансий и медиана предлагаемой зарплаты

| Сфера              | Вакансий | Медиана, ₽ | Сфера                 | Вакансий | Медиана, ₽ |
|--------------------|----------|------------|-----------------------|----------|------------|
| Здравоохранение    | 588      | 31 134     | Транспорт, логистика  | 213      | 50 000     |
| Продажи, торговля  | 460      | 43 000     | Сельское хозяйство    | 184      | 35 000     |
| Образование, наука | 439      | 27 093     | Электроэнергетика     | 182      | 52 529     |
| Производство       | 360      | 45 200     | Рабочие специальности | 170      | 45 000     |
| ЖКХ, эксплуатация  | 235      | 32 000     | Строительство         | 115      | 50 767     |

- 88,5% вакансий — на опыт от нуля до одного года; топ профессий: продавец-кассир, пекарь, дворник.
- Топ-10 работодателей дают 22,2% вакансий, при этом 476 работодателей имеют одну вакансию.

# Рынок товаров и услуг: как считает goods.py

Объекты OSM + стоимостной разрез из статистики

| Что считаем                    | Откуда берём                          | Как                                                                             |
|--------------------------------|---------------------------------------|---------------------------------------------------------------------------------|
| Форматы магазинов              | objects_by_city.csv, shop             | подсчёт по значениям supermarket / convenience / general и их доли              |
| Торговые сети                  | objects_by_city.csv, brand и operator | частота брендов; доля объектов с указанной сетью                                |
| Производства по видам          | objects_by_city.csv, industrial       | частота видов и доля нефти и газа                                               |
| Территории                     | objects_by_city.csv, settlement       | магазины, услуги и производства по городам; доли трёх крупнейших городов        |
| Промышленность, АПК, розница   | табл. 1.1, вторая часть               | отгрузка по четырём видам деятельности; сумма — это промышленность всего        |
| Соотношение размещения и денег | оба источника                         | объекты сопоставляются с миллиардами рублей: размещение и масштаб — разные вещи |

```
manuf = rv.require(t, "1.1", label="обрабаты-  
вающие производства", part=1) # 799  
mining = rv.require(t, "1.1", label="добыча  
полезных ископаемых", part=1) # 70,4  
industry = mining + manuf + energy + water # 1 039,3
```

Выход: analiz/объекты\_по\_городам.csv (52 территории) и analiz/товары\_сводка.csv.

# Рынок товаров и услуг: результаты

Размещение объектов и денежный масштаб

| Форматы магазинов | Объектов | Доля  |
|-------------------|----------|-------|
| Магазин у дома    | 951      | 60,3% |
| Супермаркет       | 621      | 39,4% |
| Общий профиль     | 4        | 0,3%  |

| Производства по видам  | Объектов |
|------------------------|----------|
| factory — завод        | 12       |
| oil — нефть            | 10       |
| gas — газ              | 9        |
| склады, цемент, прочие | 10       |

**Всего в блоке: 1 576 магазинов · 268 объектов услуг · 41 производство**

- Торговые сети: Магнит 122, Пятёрочка 94, Гроздь 22; сетей 33, но бренд указан лишь у 20,7% магазинов.
- Территории: 63,5% магазинов — в Саратове, Балаково и Энгельсе; на Саратов приходится 41,5%.
- Деньги: промышленность 1 039,3 млрд ₽ (из них обработка 799), АПК 282,1 млрд ₽, розница 648,5 млрд ₽.
- 46% размеченных производств — нефть и газ; адрес улицы указан только у 18,9% объектов OSM.

Главное противоречие: по объектам магазинов в 38 раз больше, чем производств, а по деньгам промышленность больше розницы в 1,6 раза. OSM описывает размещение, статистика — масштаб.

# Выводы

- Собран полный набор данных: 476 таблиц сборника, 4 183 вакансии, 2 432 объекта OSM — всё скриптами, числа в аналитике не переписаны вручную.
- Экономика индустриально-аграрная: третичный сектор 54,1% ВРП и 66,6% занятости, реальный сектор — 31,4% ВРП.
- Население сокращается (–5,3% с 2010 г.) при росте ВРП в 3,6 раза — рост за счёт производительности.
- Финансовый сектор: сеть сжалась в 22 раза (66 → 3 филиала), вклады выросли в 6 раз — до 585,1 млрд ₽; 51,8% вкладов населения — в Сбербанке.
- Рынок труда: медиана предлагаемой зарплаты 38 000 ₽ против 58 626 ₽ средней фактической; самый высокий спрос — в сферах с самой низкой оплатой.
- Рынок товаров и услуг: 63,5% магазинов в трёх городах; промышленность по деньгам больше розницы в 1,6 раза, хотя по числу объектов картина обратная.
- Ограничения: выборка вакансий 52,7% и смещена к ключевым словам; OSM неполон по промышленным объектам; показатели в текущих ценах.
- Развитие: второй источник вакансий, снятие смещения выборки, дефляция рядов, карта объектов по координатам.